

Deviner le genre d'un livre à partir de son résumé

Une baseline à règles, un réseau de neurones
et un Transformer comparés sur les mêmes données



Arno GUILLARME, Clément OTERO, Elyes DOS SANTOS, Faikidine AHMED et Nathan GUIHOT

Étudiants ingénieurs à CY Tech

Enseignant Ian Hang

Code source github.com/guinat/school-project-nlp-20262027

Table des matières

Introduction	2
1 Les données	2
1.1 D'où viennent les résumés	2
1.2 Découpage et déséquilibre	2
2 Les trois méthodes	3
2.1 La baseline à règles	3
2.2 Le modèle de Deep Learning	3
2.3 Le Transformer	3
2.4 Une évaluation commune	3
3 Résultats	4
3.1 Le classement général	4
3.2 Le détail par genre	4
3.3 Une hypothèse sur la règle du Transformer	5
4 Analyse des erreurs	5
5 Conclusion	6
Annexes	7
Annexe A – Glossaire	7
Annexe B – Figures et coûts	8
Annexe C – Règles de réponse	9
Annexe D – La part du hasard	9
Annexe E – Les erreurs en détail	10
Annexe F – Refaire nos expériences	11
Bibliographie	12

Introduction

Une librairie en ligne reçoit chaque semaine des fiches de livres dont le genre n'est pas renseigné. Nous avons cherché à savoir si un programme pouvait deviner ce genre en lisant seulement le résumé du livre, et quelle méthode s'y prête le mieux.

Nous avons comparé trois approches, de la plus simple à la plus lourde. La première compte des mots-clés choisis à la main. La deuxième est un petit réseau de neurones entraîné sur nos données. La troisième part de DistilBERT, un modèle de langue déjà entraîné sur une grande quantité de textes anglais, que nous avons adapté à notre tâche. Les trois systèmes ont été testés sur les mêmes livres et notés avec le même code. Les termes un peu techniques sont repris dans un glossaire, [en annexe A](#).

1 Les données

1.1 D'où viennent les résumés

Nous sommes partis du jeu de données public *Book Genre Prediction*, publié sur Kaggle [1]¹. Il réunit 4 657 résumés de livres en anglais, chacun associé à l'un des dix genres du Tableau 1.

Après avoir retiré les résumés vides, les restes de code HTML et les doublons, il reste 4 535 résumés. Certains livres apparaissaient deux fois avec deux genres différents. Nous ne les avons gardés qu'une fois, avec leurs deux genres. C'est rare (2 % des résumés), mais cela oblige les systèmes à pouvoir proposer plus d'un genre.

La moitié des résumés font moins de 196 mots, mais les écarts sont énormes. Le plus court compte 6 mots et le plus long 5 663.

Tableau 1 – Les dix genres et leur nombre de résumés dans chaque groupe

Genre	Ce que le genre regroupe	Entraînement	Validation	Test
thriller	suspense, espionnage, tueurs en série	807	101	114
fantasy	magie, dragons, mondes imaginaires	691	86	97
science	science-fiction et livres de sciences	509	64	72
horror	horreur, fantômes, surnaturel	473	59	66
history	romans historiques, livres d'histoire	472	59	66
crime	romans policiers, enquêtes	395	49	56
romance	histoires d'amour	88	11	12
psychology	livres de psychologie	79	10	11
travel	récits de voyage	79	10	11
sports	sport, sportifs	67	8	9
Total de résumés		3 580	447	508

Un livre qui a deux genres compte dans les deux lignes. Les quatre genres en gras sont les petits genres, avec moins de 100 résumés d'entraînement chacun.

1.2 Découpage et déséquilibre

Les résumés ont été répartis une fois pour toutes en trois groupes qui gardent les mêmes proportions de genres. Le premier sert à l'entraînement, le deuxième à la validation, c'est-à-dire aux réglages, et le dernier au test final. Le test n'a servi qu'une seule fois, à la toute fin. Le hasard est fixé par une graine (67 pour le découpage, 42 pour les modèles), ce qui permet de refaire exactement les mêmes expériences.

Les genres sont très déséquilibrés. Les quatre plus petits ne représentent que 8 % des livres du test, avec 9 à 12 livres chacun. Ils pèsent pourtant lourd dans notre note principale, le F1 macro, qui donne le même poids à chacun des dix genres.

1. <https://www.kaggle.com/datasets/athu1105/book-genre-prediction>

2 Les trois méthodes

Tableau 2 – Les trois systèmes en résumé

	Baseline	Deep Learning	Transformer
Principe	des mots-clés choisis à la main	un petit réseau de neurones entraîné sur nos résumés	un grand modèle de langue déjà entraîné, adapté à nos genres
Ce qu’il lit	272 mots-clés, sans le reste du texte	20 000 mots et paires de mots, sans leur ordre	le début du résumé, dans l’ordre
Apprentissage	aucun	sur nos 3 580 résumés	sur de l’anglais, puis sur nos résumés
Règle de réponse	le genre qui a le plus de points, plus ceux qui atteignent 90 % de ce score	le genre le plus probable, plus ceux dont la probabilité atteint 80 %	chaque genre dont la probabilité atteint 50 %, donc parfois aucun

2.1 La baseline à règles

La baseline n’apprend rien. Elle s’appuie sur une liste de 272 mots-clés rangés par genre. Un indice fort comme « vampire » rapporte 2,5 points au genre horror, un indice faible comme « blood » un seul point.

Le programme additionne les points et répond le genre qui en a le plus. S’il ne trouve aucun mot-clé, il répond thriller, le genre le plus fréquent. On sait donc toujours pourquoi il a répondu, mais il ne comprend pas le contexte.

2.2 Le modèle de Deep Learning

Le deuxième système est un petit réseau de neurones écrit avec PyTorch. Chaque résumé est d’abord transformé en 20 000 nombres par la méthode TF-IDF. Chacun correspond à un mot ou à une paire de mots fréquente dans les résumés d’entraînement, une fois retirés les mots vides de l’anglais comme *the* ou *and*. Sa valeur est d’autant plus grande que le terme revient souvent dans ce résumé et rarement dans les autres.

Le réseau n’a qu’une couche cachée de 256 neurones. Pendant l’apprentissage, une erreur sur un genre rare coûte plus cher qu’une erreur sur un genre fréquent, pour que romance ou sports ne soient pas sacrifiés. L’apprentissage s’arrête quand le F1 macro de validation ne progresse plus, et nous gardons le modèle du septième passage sur les données (*voir annexe B*).

Au départ, ce réseau donnait un genre dès que sa probabilité atteignait 50 %. En validation, il ne répondait alors rien pour 22 % des livres et en proposait plusieurs pour 13 % d’entre eux, alors que seuls 2 % en ont vraiment deux. Nous avons donc changé la règle. Il donne maintenant toujours le genre le plus probable, et n’en ajoute un autre que si sa probabilité atteint 80 %. L’accuracy de validation est ainsi passée de 0,559 à 0,700, et le F1 macro de 0,689 à 0,716 (*voir annexe C*).

2.3 Le Transformer

Le troisième système part de DistilBERT [2], une version allégée du modèle BERT [3], déjà entraînée sur une grande quantité de textes anglais. Nous lui avons ajouté une couche de sortie qui donne un score par genre, puis nous l’avons entraîné cinq passages de plus sur nos résumés.

Contrairement au TF-IDF, ce modèle tient compte de l’ordre des mots et de leur contexte. Il ne lit en revanche que le début de chaque résumé, 256 morceaux de mots au plus, si bien que 48 % des résumés du test sont coupés. Il a aussi gardé la règle de départ, un genre dès que sa probabilité atteint 50 %, ce qui peut le conduire à ne rien répondre.

2.4 Une évaluation commune

Les trois systèmes sont notés par le même code, sur les mêmes 508 livres du test. Ce code retrouve exactement les notes que chaque système avait calculées de son côté. Pour l’accuracy, un livre ne compte comme juste que si ses genres sont tous trouvés, sans genre en trop. Notre note principale

est le F1 macro, parce qu’il donne autant de poids aux petits genres qu’aux grands. Les temps sont mesurés dans les mêmes conditions pour les trois systèmes.

3 Résultats

Tableau 3 – Résultats sur les 508 livres du test, les meilleures notes en gras

Méthode	Accuracy	Précision	Rappel	F1 macro	Entraînement	Réponse	Taille
Baseline	0,415	0,426	0,613	0,464	0 s	1,15 ms	21 ko
Deep Learning	0,701	0,764	0,707	0,730	2,9 s	0,12 ms	22 Mo
Transformer	0,650	0,754	0,584	0,654	451 s	10,3 ms	268 Mo

Les notes vont de 0 à 1, et précision, rappel et F1 sont des moyennes sur les dix genres. Les deux réseaux ont été entraînés sur la puce graphique d’un Mac, et le temps passé à écrire les règles de la baseline n’est pas compté. La réponse est le temps moyen pour classer un résumé sur le processeur. La taille est celle du fichier du modèle.

3.1 Le classement général

Le modèle de Deep Learning obtient les meilleures notes sur les quatre mesures. Il trouve exactement les bons genres pour 70 % des livres, avec un F1 macro de 0,730. C’est aussi le plus rapide à l’usage, environ 85 fois plus que le Transformer sur un processeur.

Le Transformer arrive deuxième. Quand il répond, il se trompe peu (précision de 0,754), mais il oublie beaucoup de livres (rappel de 0,584). Sa règle de réponse en est la cause. Pour 83 livres du test, soit 16 %, aucun genre n’atteint 50 % et il ne répond rien. Dans 41 de ces cas, le genre auquel il croyait le plus était pourtant le bon. C’est exactement le défaut qu’avait le Deep Learning avant qu’on change sa règle.

La baseline est loin derrière, avec un F1 macro de 0,464. Elle propose souvent plusieurs genres à la fois, 78 fois sur 508 alors que seuls 6 livres du test en ont deux. Elle trouve ainsi beaucoup de bons genres, mais aussi beaucoup de faux.

Avec 508 livres, une note peut varier selon les livres tirés. Un test statistique (*voir annexe D*) montre que l’avance du Deep Learning sur le Transformer n’est probablement pas due au hasard.

3.2 Le détail par genre

Tableau 4 – F1 de chaque genre sur le test, le meilleur de chaque ligne en gras

Genre	Livres	Base.	DL	Transf.	Genre	Livres	Base.	DL	Transf.
thriller	114	0,44	0,66	0,73	crime	56	0,46	0,69	0,67
fantasy	97	0,63	0,77	0,80	romance	12	0,45	0,53	0,00
science	72	0,57	0,74	0,73	psychology	11	0,47	0,91	0,74
history	66	0,40	0,78	0,71	travel	11	0,17	0,80	0,71
horror	66	0,46	0,61	0,65	sports	9	0,58	0,82	0,80
6 grands genres		0,49	0,71	0,72	4 petits genres		0,42	0,77	0,56

La colonne Livres donne le nombre de livres du genre dans le test. La dernière ligne donne le F1 moyen des grands et des petits genres.

Le détail par genre nuance ce classement. Sur les six grands genres, les deux réseaux font jeu égal, et le Transformer fait même mieux pour thriller, fantasy et horror. La différence vient des quatre petits genres, où le Deep Learning obtient un F1 moyen de 0,77 contre 0,56. Le Transformer ne reconnaît jamais la romance. Comme ces genres n’ont que 9 à 12 livres de test, un ou deux livres suffisent toutefois à faire bouger leur note.

Les matrices de confusion (*voir annexe B*) montrent aussi quelques habitudes. La baseline range beaucoup de thrillers en crime, 36 sur 110, parce que le vocabulaire de l’enquête fait partie de ses mots-clés crime. Le Deep Learning envoie assez souvent vers thriller, le genre le plus fréquent, des livres crime, horror ou history, mais il se trompe aussi dans l’autre sens.

3.3 Une hypothèse sur la règle du Transformer

Nous n'avons pas eu le temps de changer la règle de réponse du Transformer. Toutes ses notes sont donc celles de sa règle de départ, un genre dès que sa probabilité atteint 50 %. Nous sommes toutefois conscients que cette règle le désavantage. Notre hypothèse est qu'il ferait nettement mieux s'il donnait toujours le genre le plus probable, un critère dit « argmax », quitte à ajouter un second genre quand sa probabilité est très élevée, comme le fait le Deep Learning.

Deux constats appuient cette hypothèse. Le Deep Learning a beaucoup gagné avec ce seul changement, et le Transformer reste muet pour 83 livres du test alors que, pour 41 d'entre eux, le genre qu'il plaçait en tête était le bon. Ce gain reste pourtant à vérifier. Il faudrait choisir la nouvelle règle sur la validation, puis la tester une seule fois sur le test (voir [annexe C](#)). En attendant, nous comparons les trois systèmes avec leurs règles actuelles.

4 Analyse des erreurs

Pour ne pas choisir les erreurs qui nous arrangent, nous avons fixé à l'avance huit types d'erreurs, puis tiré au hasard un exemple de chaque type, deux pour le premier (voir [annexe E](#)). Sur tout le test, 88 livres sont mal classés par les trois systèmes et 151 sont bien classés par les trois.

Tableau 5 – Les neuf erreurs tirées au hasard (∅ signifie aucune réponse, le gras une réponse juste)

N°	Livre	Vrai genre	Baseline	Deep L.	Transf.	Cause probable
38	<i>Ring</i>	horror	crime	thriller	∅	écrit comme une enquête
379	<i>La Peau froide</i>	horror	travel	thriller	∅	23 mots, aucun indice
236	<i>The Affair</i>	thriller	crime	thriller	thriller	piège de mots-clés
219	<i>The Roanoke Girls</i>	thriller	romance, horror	romance	∅	suspense jamais nommé
436	<i>The Girl Next Door</i>	thriller	travel	horror	horror	souvent classé en horreur
116	<i>Firmin</i>	fantasy	thriller	horror	horror	il faut comprendre le sens
481	<i>City of Bones</i>	romance, fantasy	crime	fantasy	fantasy	romance seulement suggérée
136	<i>Neon Gods</i>	romance	fantasy	fantasy	fantasy	romance mythologique
12	<i>Perfect Chemistry</i>	romance	romance	thriller	∅	petit genre, réseaux hésitants

Les pièges de mots-clés. Dans un roman de la série Jack Reacher (n° 236), les mots « murderer », « investigation » et « police » donnent 4,5 points à crime contre un seul à thriller. Ailleurs, l'expression « a quick tour of his neighborhood » suffit à déclencher le genre travel (n° 436). Les deux réseaux, qui ont appris sur des exemples, évitent ces pièges.

Un Transformer trop prudent. Pour *Ring* (n° 38), le Transformer place bien horror en tête, mais à 49 % seulement, et ne répond donc rien. Même chose pour *Perfect Chemistry* (n° 12), avec romance à 38 %.

Des genres voisins. Le suspense de *The Roanoke Girls* (n° 219) n'est jamais nommé, et le Deep Learning hésite entre romance et horror, à 48 % chacun. Dans *Firmin* (n° 116), le côté fantastique vient d'un rat qui apprend à lire. Aucun mot isolé ne le révèle.

Les limites des données. Un résumé de 23 mots sans aucun indice ne peut pas être classé (n° 379). *Neon Gods* (n° 136) est à la fois une romance et de la fantasy, mais il n'a reçu qu'une étiquette. Nous avons aussi trouvé dans les textes un reste du site Goodreads, le mot « (less) », présent dans tous les résumés de romance d'entraînement et dans aucun résumé crime ou travel. Les modèles pourraient s'en servir à tort. L'effet reste faible, le F1 du Transformer ne passant que de 0,654 à 0,648 quand on le retire, mais il faudrait le supprimer.

5 Conclusion

Tableau 6 – Comparaison finale des trois systèmes

	Baseline	Deep Learning	Transformer
F1 macro	0,464	0,730	0,654
Petits genres (F1)	0,42	0,77	0,56, jamais la romance
Coût	aucun entraînement	2,9 s d'entraînement, 22 Mo	7,5 min d'entraînement, 268 Mo
Simplicité	chaque réponse s'explique	une seule couche cachée	modèle lourd, peu explicable
Limite principale	ignore le contexte	ignore l'ordre des mots	se tait quand il doute

Nous retenons le modèle de Deep Learning. Il a les meilleures notes globales et traite bien mieux les petits genres. Il s'entraîne en moins de trois secondes sur la puce graphique d'un Mac, puis classe un résumé en 0,12 ms sur un simple processeur. Réentraîné deux fois avec la graine 42 sur le même Mac, il a donné exactement les mêmes réponses.

Le Transformer n'est pas à écarter pour autant. Il fait déjà mieux sur plusieurs grands genres, et nous pensons qu'une règle de type argmax, qui répond toujours, réduirait nettement son retard, même si nous ne l'avons pas vérifié. Il reste cependant bien plus lourd et, avec sa règle actuelle, moins fiable sur les genres rares. La baseline, elle, garde son intérêt comme point de départ, parce qu'on comprend toujours ses réponses.

Ce travail nous a surtout appris trois choses. Le plus gros modèle n'est pas forcément le meilleur. La règle qui transforme un score en réponse pèse lourd sur les notes. Et la qualité des données limite tous les systèmes, quels qu'ils soient. Avec plus de temps, nous vérifierions notre hypothèse en faisant toujours répondre le Transformer, nous retirerions « (less) » des résumés et nous chercherions plus de livres pour les petits genres.

Annexes

Annexe A – Glossaire

Terme	Sens dans ce rapport
Accuracy	Part des livres pour lesquels le système donne exactement les bons genres, ni plus ni moins.
Précision d'un genre	Parmi les livres que le système range dans ce genre, part de ceux qui en font vraiment partie.
Rappel d'un genre	Parmi les livres de ce genre, part de ceux que le système retrouve.
F1	Moyenne de la précision et du rappel, qui reste basse dès que l'une des deux l'est.
F1 macro	Moyenne du F1 des dix genres, chacun pesant autant quelle que soit sa taille.
Entraînement, validation, test	Les trois groupes de résumés. Ils servent à apprendre, à régler, puis à noter une seule fois à la fin.
Graine	Nombre qui fixe le hasard de l'ordinateur, pour retrouver les mêmes résultats à chaque exécution.
TF-IDF	Façon de transformer un texte en nombres, où un terme compte d'autant plus qu'il est fréquent dans ce texte et rare dans les autres.
Réseau de neurones	Programme fait de couches de calculs simples, dont les réglages (les paramètres) sont appris sur des exemples.
Passage (époque)	Une lecture complète de tous les résumés d'entraînement.
Loss	Mesure de l'erreur du modèle pendant l'apprentissage, que l'on cherche à faire baisser.
Sur-apprentissage	Le modèle retient les exemples d'entraînement par cœur et devient moins bon sur des textes nouveaux.
Transformer, affinage	Modèle qui lit un texte en tenant compte du contexte de chaque mot. L'affinage consiste à continuer son entraînement sur nos propres données.
Règle de réponse	Façon de passer des scores d'un système à une liste de genres, par exemple en gardant tout genre dont la probabilité atteint 50 %.
Matrice de confusion	Tableau qui croise le vrai genre et le genre prédit, pour voir quelles erreurs reviennent.
Intervalle de confiance	Fourchette dans laquelle la note se trouverait probablement avec d'autres livres de test.
Puce graphique (MPS)	Processeur graphique du Mac, bien plus rapide que le processeur principal pour entraîner un réseau de neurones.

Annexe B – Figures et coûts

Tableau 7 – Ce que coûte chaque système

Méthode	Paramètres	Fichier	Entraînement	Réponse CPU	Réponse GPU
Baseline	0 (272 mots-clés)	21 ko	0 s	1,15 ms	–
Deep Learning	5,1 millions	22 Mo	2,9 s	0,12 ms	0,15 ms
Transformer	67 millions	268 Mo	451 s (7,5 min)	10,3 ms	5,6 ms

Toutes les mesures ont été faites sur le même Mac, avec les 508 résumés du test, après un premier passage de chauffe qui n'est pas compté. Les deux réseaux ont été entraînés sur la puce graphique (GPU), et le temps du Deep Learning est la médiane de deux entraînements. Le temps de réponse est la médiane de trois passages, ramenée à un résumé.

Pour la baseline, la taille est celle du fichier de code, lexique compris.




Figure 1 – Matrices de confusion sur les 502 livres du test qui n'ont qu'un seul genre. Chaque ligne est un vrai genre et chaque colonne un genre prédit, la dernière colonne comptant les livres restés sans réponse. Quand un système se trompe, on compte le genre auquel il croyait le plus. Plus une case est foncée, plus elle regroupe une grande part des livres de sa ligne.




Figure 2 – F1 de chaque genre sur le test, n étant le nombre de livres du genre. Avec sa règle de 50 %, le Transformer ne trouve jamais la romance.




Figure 3 – Courbes d’apprentissage, avec la loss sur l’entraînement et sur la validation après chaque passage. Dans les deux cas, la loss de validation cesse de baisser alors que celle d’entraînement continue, signe que le modèle commence à apprendre par cœur. Le pointillé marque le modèle gardé, celui qui a le meilleur F1 macro de validation. Pour le Deep Learning, la loss de validation la plus basse arrive un passage plus tôt. Les deux échelles ne sont pas comparables, car la loss du Deep Learning donne plus de poids aux petits genres.

Annexe C – Règles de réponse

Le Tableau 8 montre pourquoi la règle du Deep Learning a changé en cours de projet. La première version donnait chaque genre dont la probabilité atteignait 50 %, comme le Transformer. La version finale donne toujours le genre le plus probable et n’en ajoute un autre qu’à partir de 80 %. Les deux versions sont entraînées de la même façon, seule la règle diffère.

Tableau 8 – Le Deep Learning sur la validation selon sa règle de réponse

Règle	Accuracy	F1 macro	Sans réponse	Plusieurs genres
Chaque genre à 50 % (première version)	0,559	0,689	22 %	13 %
Le plus probable, plus ceux à 80 % (version finale)	0,700	0,716	0 %	2 livres sur 447

Sur la validation, seuls 2 % des livres ont vraiment deux genres.

Nous n’avons pas appliqué ce changement au Transformer, qui garde la règle de la première version. Nous faisons l’hypothèse qu’une règle de type argmax, qui donne toujours le genre le plus probable, améliorerait surtout son rappel. Il répondrait alors aussi pour les 83 livres du test qu’il laisse aujourd’hui sans réponse, dont 41 où son premier choix est juste. Cette règle aiderait aussi les petits genres comme la romance, que le Transformer place parfois en tête avec une probabilité trop basse pour la donner (*Perfect Chemistry*, n° 12, avec romance à 38 %). Il faudrait ensuite choisir sur la validation le seuil au-delà duquel un second genre est ajouté, puis appliquer la règle une seule fois au test, comme nous l’avons fait pour le Deep Learning. Même vérifié, un gain sur les petits genres serait à prendre avec prudence, car quelques livres suffisent à faire bouger leur note.

Annexe D – La part du hasard

Pour estimer la part de hasard, nous avons tiré 1 000 fois un nouveau test de 508 livres, avec remise, parmi les livres du test (méthode du *bootstrap*, graine 42). Dans 95 % des tirages, la note tombe dans la fourchette indiquée, qui forme l’intervalle de confiance. Pour comparer l’accuracy de deux systèmes, le test de McNemar s’intéresse aux livres où un seul des deux a raison. Une valeur p inférieure à 0,05 indique que l’écart n’est probablement pas dû au hasard.

Tableau 9 – Intervalles de confiance à 95 % du F1 macro sur le test

Méthode	F1 macro	Intervalle de confiance
Baseline	0,464	de 0,414 à 0,507
Deep Learning	0,730	de 0,669 à 0,777
Transformer	0,654	de 0,596 à 0,696

Tableau 10 – Comparaisons deux à deux, système A contre système B

A contre B	Écart de F1	Intervalle de l'écart	Justes pour A seul	Justes pour B seul	p (Mc-Nemar)
Deep Learning contre Transformer	0,076	de 0,015 à 0,135	77	51	0,027
Deep Learning contre Baseline	0,266	de 0,203 à 0,331	180	35	$1 \cdot 10^{-24}$

Annexe E – Les erreurs en détail

Les huit types d'erreurs ont été fixés avant le tirage. Le nombre entre parenthèses indique combien de livres du test correspondent à chaque type.

- Les trois systèmes se trompent (88).
- Seule la baseline se trompe (128).
- Le Transformer ne répond rien (83).
- Confusion entre thriller, crime et horror (61).
- Confusion entre fantasy et horror (18).
- Livre à plusieurs genres (6).
- Genre douteux, quand les deux réseaux sont d'accord contre l'étiquette avec au moins 80 % de probabilité (7).
- Petit genre manqué par le Deep Learning (13).

Le tableau suivant donne, pour chaque erreur, les mots-clés trouvés par la baseline avec leurs points, puis les trois genres les plus probables selon chacun des deux réseaux.

N°	Baseline, points et mots-clés trouvés	Deep Learning, probabilités	Transformer, probabilités
38	crime 2 (investigation, witnesses)	thriller 0,37 / crime 0,30 / horror 0,22	horror 0,49 / thriller 0,47 / crime 0,08
379	travel 1 (island)	thriller 0,64 / romance 0,25 / travel 0,23	science 0,18 / thriller 0,16 / horror 0,07
236	crime 4,5 (murderer, investigation, police), history 1 (soldier), thriller 1 (killer)	thriller 0,89 / crime 0,20 / horror 0,18	thriller 0,94 / romance 0,04 / fantasy 0,03
219	horror 1 (darkness), romance 1 (heart)	romance 0,48 / horror 0,48 / fantasy 0,26	horror 0,35 / thriller 0,17 / fantasy 0,14
436	travel 3,5 (travel, tour), crime 2 (crime, police)	horror 0,39 / history 0,22 / science 0,19	horror 0,68 / thriller 0,15 / crime 0,04
116	aucun mot-clé, donc thriller par défaut	horror 0,40 / science 0,33 / fantasy 0,27	horror 0,64 / thriller 0,09 / fantasy 0,08
481	crime 7 (murder, murderers, police, witness), fantasy 3 (demon, demons, warriors), horror 1 (blood)	fantasy 0,55 / horror 0,43 / romance 0,33	fantasy 0,75 / horror 0,18 / thriller 0,03
136	fantasy 2,5 (spell), history 1 (war), thriller 1 (dangerous)	fantasy 0,85 / romance 0,27 / thriller 0,20	fantasy 0,94 / romance 0,06 / horror 0,04
12	romance 4,5 (passionate, boyfriend, chemistry), crime 1 (clue), thriller 1 (secret)	thriller 0,59 / romance 0,38 / sports 0,26	romance 0,38 / thriller 0,29 / sports 0,19

Voici le début des résumés concernés, en anglais.

- 38 “After four teenagers mysteriously die simultaneously in Tokyo, Kazuyuki Asakawa, a reporter [...] decides to launch his own personal investigation.”
- 379 “The novel chronicles the stay of an unnamed weather official on a remote island in the south Atlantic close to the Antarctic Circle.”
- 236 “March 1997. A woman has her throat cut behind a bar in Carter Crossing, Mississippi. [...] Is the murderer a local guy - or is he a soldier?”

219 “Lane Roanoke is fifteen when she comes to live with her grandparents [...] either the girls run, or they die.”
436 “The story takes place in 1960s suburban United States [...] After giving the reader a quick tour of his neighborhood [...]”
116 “Firmen, is a rat and the runt son of an alcoholic mother living in 1960s Boston [...] eventually he learns to read.”
481 “When fifteen-year-old Clary Fray heads out to the Pandemonium Club in New York City, she hardly expects to witness a murder [...]”
136 “He was supposed to be a myth. But from the moment I crossed the River Styx and fell under his dark spell [...]”
12 “A fresh, urban twist on the classic tale of star-crossed lovers. When Brittany Ellis walks into chemistry class [...]”

Annexe F – Refaire nos expériences

Tout le code est dans le dépôt, et le fichier `README.txt` détaille chaque étape. Avec Python 3.12 et l’outil `uv`, les commandes principales sont les suivantes.

```
uv sync                                # installe les dépendances
uv run jupyter nbconvert --to notebook --execute \
    --inplace notebooks/projet.ipynb  # exécute le notebook
uv run python src/run_evaluation.py    # relance les 3 systèmes (1 min)
uv run python src/run_evaluation.py --stage history
                                       # première version du Deep Learning
uv run python src/analysis.py          # refait tableaux, figures, erreurs
```

Tous les chiffres de ce rapport viennent des fichiers du dossier `results/evaluation/`, produits par ces commandes.

Bibliographie

- [1] athu1105, *Book Genre Prediction*, jeu de données publié sur Kaggle.
<https://www.kaggle.com/datasets/athu1105/book-genre-prediction>
- [2] V. Sanh, L. Debut, J. Chaumond, T. Wolf, *DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter*, 2019.
<https://arxiv.org/abs/1910.01108>
- [3] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*, 2019.
<https://arxiv.org/abs/1810.04805>
- [4] Hugging Face, *Transformers*, documentation officielle.
<https://huggingface.co/docs/transformers>
- [5] PyTorch, documentation officielle.
<https://pytorch.org/docs/stable/>
- [6] scikit-learn, *TfidfVectorizer*, documentation officielle.
https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html
- [7] scikit-learn, *Metrics and scoring: quantifying the quality of predictions*, documentation officielle.
https://scikit-learn.org/stable/modules/model_evaluation.html
- [8] *iterative-stratification*, bibliothèque Python de découpage stratifié pour données multi-label.
<https://github.com/trent-b/iterative-stratification>